

MACHINE LEARNING · CLIMA · OCIO

Salimos Hoy?

Recomendador inteligente de actividades de ocio impulsado por Machine Learning y datos meteorológicos en tiempo real.

El mejor momento para tu actividad, sin adivinar.

Consulta el clima en tiempo real, elige una actividad y recibe una recomendación clara sobre cuándo salir, basada en análisis climático y aprendizaje automático.

☀️ Clima en tiempo real

💡 Recomendación inteligente

🕒 Hora óptima

[Elegir actividad](#)

EL PROBLEMA

¿Por qué es tan difícil planificar el ocio?

Clima impredecible

La lluvia, el viento o el calor extremo arruinan planes sin aviso previo.

Información dispersa

No existe un sistema que cruce actividad, ciudad y condiciones meteorológicas en un solo lugar.

Decisiones a ciegas

La mayoría elige actividades sin datos objetivos, generando frustración y pérdida de tiempo.



Made with GAMMA

API

Usamos **Open-Meteo** porque ofrece datos meteorológicos fiables, gratuitos y fáciles de integrar, sin necesidad de autenticación compleja. Nos permite consultar tanto la ubicación de una ciudad como su pronóstico horario en una sola arquitectura simple y escalable.

¿Qué hace Open-Meteo?

Es una API de meteorología que devuelve información de pronóstico y variables climáticas por ubicación. Primero geocodificamos la ciudad para obtener coordenadas y después consultamos el pronóstico con esas coordenadas.

¿Por qué la elegimos?

- Datos horarios detallados y consistentes
- Integración simple con dos endpoints principales
- Compatible con múltiples ciudades y escalable para análisis
- Ideal para cruzar clima y actividad turística

Variables meteorológicas consultadas

Estas variables se usan como características de entrada para el modelo de machine learning: combinan condiciones instantáneas del pronóstico con señales históricas para capturar patrones de temperatura, humedad, viento, nubosidad y radiación. Así, el modelo puede comparar el estado actual con el comportamiento pasado de cada ciudad y mejorar la predicción.

Geocoding API

Función: Geocoding busca ciudades y obtiene las coordenadas.

Forecast API

1

temperature_2m

Temperatura del aire a 2 metros.

2

apparent_temperature

Sensación térmica percibida.

3

relative_humidity_2m

Humedad relativa a 2 metros.

4

precipitation_probability

Probabilidad de precipitación.

5

wind_speed_10m

Velocidad del viento a 10 metros.

6

wind_gusts_10m

Rachas máximas de viento a 10 metros.

7

cloud_cover

Porcentaje de cobertura nubosa.

8

uv_index

Índice de radiación ultravioleta.

Variables meteorológicas consultadas

Historical API

1

temperature_2m

Temperatura del aire a 2 metros.

2

apparent_temperature

Sensación térmica percibida.

3

relative_humidity_2m

Humedad relativa a 2 metros.

4

precipitation

Precipitación acumulada.

5

wind_speed_10m

Velocidad del viento a 10 metros.

6

wind_gusts_10m

Rachas máximas de viento a 10 metros.

7

cloud_cover

Porcentaje de cobertura nubosa.

8

shortwave_radiation

Radiación de onda corta incidente.

Endpoints principales

- **GEOCODING_URL:** convierte nombres de ciudades en coordenadas.
- **FORECAST_URL:** obtiene los datos meteorológicos en tiempo real.

Con este flujo, primero identificamos la ciudad y luego recuperamos el pronóstico para mostrar información útil y comparable entre destinos.

DATASET MODELO INICIAL

117K

Registros históricos

Datos meteorológicos reales sin valores nulos.

60

Ciudades globales

Cobertura en múltiples regiones climáticas del mundo.

22

Variables de entrada

Temperatura, humedad, UV, viento, lluvia, región y más.


0

Valores nulos

Dataset completamente limpio y listo para entrenar.

Fuente: **Open Meteo API**. Variable objetivo: recommendation – problema de clasificación multicategoría con relaciones no lineales entre clima, actividad y horario.

Clases reales, desequilibrio natural




¿Qué nos dice la distribución?

El 78% de las combinaciones clima-actividad son favorables. Solo el 5% son condiciones claramente malas.

Este desequilibrio natural exige métricas más allá de la accuracy: **F1-score por clase** y **precisión** son clave para evaluar el modelo correctamente.

i La clase "Malo" es la más crítica: un falso negativo aquí tiene mayor coste para el usuario.

Cuatro enfoques



Análisis comparativo



Decision Tree

Baseline (89.43%). Interpretable, pero limitado en generalización.



Logistic Regression

Descartado (50.17%). No captura relaciones no lineales.



Deep Learning

Evaluado. Menos eficiente en datos tabulares estructurados.

Variables del Modelo (Features)

El modelo utiliza **13 features** seleccionadas para representar el clima real sin filtrar la etiqueta desde cálculos internos.

Numéricas (9)

- temperature_2m
- apparent_temperature
- relative_humidity_2m
- precipitation_probability
- wind_speed_10m
- wind_gusts_10m
- cloud_cover
- uv_index
- hour

Categorías (4)

- activity
- continent
- climate_group
- season_block

⚠ Se excluyen `activity_score` y `comfort_distance` para evitar que el modelo aprenda directamente la etiqueta desde cálculos internos.

Un motor de ML que decide por ti



¿Cómo funciona?

El usuario elige ciudad y actividad. El sistema consulta la API meteorológica, procesa las variables con el modelo Random Forest y devuelve una recomendación clasificada en segundos.

- Integración con Open Meteo API
- 22 variables meteorológicas analizadas
- Respuesta en tiempo real
- Interfaz web minimalista y accesible

¿Por qué no necesitamos oversampling?

- El dataset tenía **117K registros**, suficientes para entrenar sin técnicas de balanceo artificial.
- El desequilibrio natural de clases (**78% favorable, 5% malo**) refleja la realidad del problema: la mayoría de combinaciones clima-actividad son favorables.
- **Random Forest** maneja bien el desequilibrio de clases sin necesidad de oversampling.
- La **accuracy** fue lo suficientemente alta sin crear datos sintéticos, así que el modelo aprendió patrones reales.

Esto es una buena señal: el sistema es robusto, generaliza bien a datos reales y no depende de información artificial para rendir bien.

Clasificación multicategoría con relaciones no lineales

1

Preprocesamiento

Encoding de variables categóricas, escalado y feature engineering.

2

Train / Test Split

Separación estratificada para preservar la distribución de clases.

3

Entrenamiento

Evaluación de múltiples algoritmos: árboles, ensembles, regresión y redes neuronales.

4

Selección del modelo

Random Forest desplegado por su superior generalización y robustez.

❗ El split estratificado es clave en problemas con clases desbalanceadas. La no linealidad del problema descarta modelos lineales desde el inicio.



Un conjunto de datos limpio, equilibrado y listo para el entrenamiento del modelo.

3,05M

Registros

Volumen total de datos históricos

200

Ciudades

Cobertura geográfica global

6

Meses estratégicos

Representación estacional equilibrada

22

Columnas

6 actividades oficiales · 0 nulos

✓ El dataset no contiene valores nulos. Las clases de **recommendation** tienen representación suficiente en todas las categorías, garantizando un entrenamiento robusto y sin sesgos.

¿Por qué no necesitamos oversampling?

- El dataset tenía **3,5M registros**, suficientes para entrenar sin técnicas de balanceo artificial.
- **Random Forest** maneja bien el desequilibrio de clases sin necesidad de oversampling.
- La **accuracy** fue lo suficientemente alta sin crear datos sintéticos, así que el modelo aprendió patrones reales.


EDA: Validaciones del Dataset

Todas las revisiones de calidad superaron los criterios establecidos antes del entrenamiento. El dataset es íntegro y reproducible.

Revisión	Resultado
Valores nulos	0
Actividades oficiales	6 actividades
Clases de recommendation	Todas > 5%
Ciudades	200 ciudades
Meses estratégicos	6 meses

Distribución de la Variable Objetivo


La variable **recommendation** presenta cuatro clases con distribución realista. La presencia significativa de las clases minoritarias evita que el modelo sea demasiado optimista.



❗ Las clases **malo** (8.33%) y **regular** (16.24%) superan el umbral mínimo del 5%, lo que garantiza que el modelo aprenda a identificar condiciones desfavorables con precisión.

Recomendación por Actividad


La distribución de clases varía significativamente según la actividad, reflejando su dependencia real con las condiciones meteorológicas.



❏ **Observación clave:** «Ir al cine» concentra el **95.9%** en «excelente» por ser una actividad de interior, independiente del clima exterior. Este comportamiento es estadísticamente coherente y esperado.

Modelos Probados y Métricas

Se evaluaron **9 modelos** en tres grupos: base, gran escala y ligeros. La métrica principal es el accuracy en test, complementada con recall de las clases minoritarias.



Modelo Final Elegido

✓ SELECCIONADO

Accuracy Test

0.994267

Recall "malo"

0.992699

Recall "regular"

0.992456

Peso del modelo

28.49 MB

Archivo: `models/light/salimos hoy_rf_100_depth16_compressed.pkl`

Decisión: RF_full alcanza 0.9989 de accuracy pero pesa ~500 MB, lo que imposibilita su despliegue en GitHub y demos públicas. **RF_100_depth16 logra 0.9943 con solo 28.49 MB**, siendo el mejor equilibrio entre rendimiento y viabilidad de producción.



PRODUCTO EN VIVO

De modelo a producto real



Selección de ciudad

El usuario elige entre 200 ciudades globales. El sistema recupera automáticamente las condiciones meteorológicas actuales.



Elección de actividad

Bicicleta, turismo, deporte, paseo... El modelo evalúa la compatibilidad clima-actividad en tiempo real.



Evaluación instantánea

El usuario selecciona una hora y recibe una clasificación inmediata: **Excelente** • Buena • Regular • Mala.



Despliegue en Render

Modelo serializado con `joblib`, backend Python y frontend web accesible en **salimoshoy.onrender.com**.

Flujo de consulta y resultados

El flujo comienza cuando el usuario selecciona **Barcelona** y la actividad **Ir al cine**. Luego, el sistema consulta datos meteorológicos en tiempo real desde la API de **Open Meteo**, procesa **22 variables climáticas** con un modelo **Random Forest** y devuelve una recomendación detallada con el nivel de compatibilidad por hora.

También, se puede escoger el modo de decision por una hora en especifico

Prepara tu consulta

Introduce una ciudad, actividad y modo de decision para generar una recomendacion.

¿Dónde estás?

Escribe el nombre de cualquier ciudad del mundo

Barcelona

✓ ¡Perfecto! Ciudad encontrada

Barcelona (Comunidad Autónoma de Cataluña), España

Actividad

Pasear o hacer senderismo

Modo de decision

Buscar mejor hora

Analizar clima

Resultado principal

Resumen directo de la mejor opcion calculada para tu consulta.

Mejor hora

10:00

Hora recomendada para salir.

Score

100.0/100

Mayor puntuacion significa mejores condiciones.

Recomendacion final

Excelente

Clasificacion climatica por hora.

Actividad

Pasear o hacer senderismo

Barcelona, Comunidad Autónoma de Cataluña, España

La mejor hora para Pasear o hacer senderismo en Barcelona, Comunidad Autónoma de Cataluña, España es a las 10:00. Las condiciones son excelente y el score es 100.0/100. A esa hora se esperan 23.4 grados, 0% de probabilidad de lluvia y viento de 4.7 km/h.

Prepara tu consulta

Introduce una ciudad, actividad y modo de decision para generar una recomendacion.

¿Dónde estás?

Escribe el nombre de cualquier ciudad del mundo

Barcelona

✓ ¡Perfecto! Ciudad encontrada

Barcelona (Comunidad Autónoma de Cataluña), España

Actividad

Pasear o hacer senderismo

Modo de decision

Evaluar hora especifica

Hora

17:00

Analizar clima

Resultado principal

Resumen directo de la mejor opcion calculada para tu consulta.

Hora evaluada

17:00

Hora seleccionada por el usuario.

Score

100.0/100

Mayor puntuacion significa mejores condiciones.

Recomendacion final

Excelente

Clasificacion climatica por hora.

Actividad

Pasear o hacer senderismo

Barcelona, Comunidad Autónoma de Cataluña, España

Mejor alternativa del día: 10:00 con score 100.0/100.

Flujo de consulta y resultados

Las visualizaciones resumen el resultado: **Ubicación analizada** muestra la ciudad seleccionada en el mapa, **Pasear o hacer senderismo** confirma la actividad elegida, **Score por hora** presenta la puntuación recomendada a lo largo del día y **Clima por variable** desglosa la evolución de la temperatura por hora.



Flujo de consulta y resultados

Top 5 mejores opciones

El modelo evalúa todas las opciones horarias y resalta las 5 mejores ventanas como las más convenientes para la actividad.

Top 5 mejores opciones del día

Ordenadas por score y distancia de confort, manteniendo la recomendacion final visible.

Hora	Score	Recomendacion final	Temperatura	Lluvia	Viento	Humedad
13:00	98.5	excelente	17.4	3	5.4	48
12:00	96.7	excelente	16.5	0	7.3	52
11:00	96.7	excelente	15.2	0	9.5	57
10:00	94	excelente	14	0	9.6	61
23:00	92.5	bueno	12.8	0	3.8	72



Conclusión Final

Datos

Dataset histórico con 3.054.400 registros, 200 ciudades, 6 meses estratégicos y 6 actividades.

EDA

Sin nulos, clases balanceadas y todas las actividades validadas correctamente.

Modelos

9 modelos comparados en tres grupos. Decisión basada en accuracy, recall y peso de despliegue.

Producto

App Streamlit funcional con clima real de Open-Meteo y clasificación en tiempo real.

«SalimosHoy? es una app funcional y defendible: datos reales, dataset amplio, comparación de modelos y despliegue eficiente.»

Gracias. · salimoshoy.onrender.com

Equipo



Kristhian Hernandez

Futuro Data Science



**Ana Belén González
Villalba**

[linkedin.com/in/ana-gonzalez-
villalba-5068bo9](https://www.linkedin.com/in/ana-gonzalez-villalba-5068bo9)

Futura Data Science



Alejandro Gutiérrez

[linkedin.com/in/alejandroantonioг
utierrez](https://www.linkedin.com/in/alejandroantonioгутierrez)

Futuro Data Science